linuxday25@poul:~$ python

build_your_transformer.py

linuxday25@poul:~$ man Questo Talk

@ Perché?

~ Questa technologia sta entrando nelle nostre vite e dispositivi

~ Per costruire ed usare applicazioni open con questi modelli è importante conoscerli (almeno un pochino)

@ Come?

~ Teoria:

$ Machine Learning

$ Transformer Block

~ Pratica:

$ Implementazione in PyTorch (no training)

linuxday25@poul:~$ man Machine Learning

@ Codice

~ Ingredienti:

$ Conoscenza del programmatore

~ Risultato:

$ Il programmatore impartisce alla macchina le operazioni da compiere per risolvere il problema

@ Machine Learning

~ Ingredienti:

$ Esempi di input – output

$ Un modello e come addestrarlo

~ Risultato:

$ Il modello impara a produrre l'output atteso dato un input

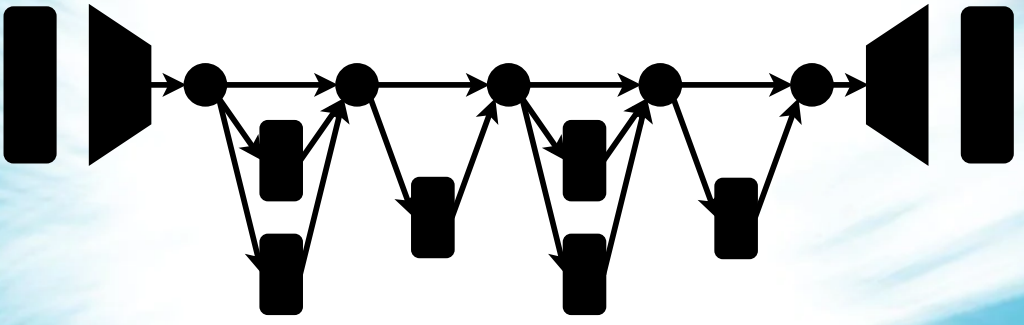

Pokémon

Come parla un Transformer?

linuxday25@poul:~$ man Rappresentazione

@ Immagini

~ Pixel

~ **RGB**, Tre numeri identificano univocamente un colore!

@ Testo

~ Parole? E se faccio erori?

~ Vettori multidimensionali? Ma che valore posso dare ad concetto?

linuxday25@poul:~$ man Rappresentazione

@ Immagini

~ Pixel

~ **RGB**, Tre numeri identificano univocamente un colore!

@ Testo

~ **Parole? E se faccio erori?**

~ Vettori multidimensionali? Ma che valore posso dare ad concetto?

linuxday25@poul:~$ man Tokenizzazione

@ Token

~ Un Token può essere visto come un **“Pixel per il Testo”**

~ É una **sotto-parola**:

$ Evita il problema degli errori grammaticali, sarebbe impossibile avere una rappresentazione univoca per ogni possibile errore grammaticale

$ Permette di assegnare rappresentazioni parzialmente condivise tra parole e le loro radici. Ad esempio Tokenizer è diviso in Token-izer

linuxday25@poul:~$ python Tokenizzazione.py

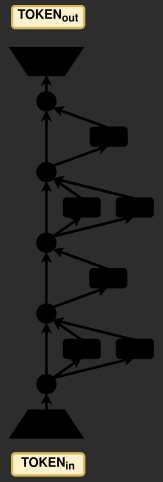

[Code Session]

linuxday25@poul:~$ man Rappresentazione

@ Immagini

~ Pixel

~ **RGB**, Tre numeri identificano univocamente un colore!

@ Testo

~ Parole? E se faccio erori?

~ **Vettori multidimensionali? Ma che valore posso dare ad concetto?**

linuxday25@poul:~$ man Embedding

@ Embedding

- Un Token viene associato ad una rappresentazione in uno spazio multi-dimensionale
- **Angolo Tra Vettori = Somiglianza di Significato**

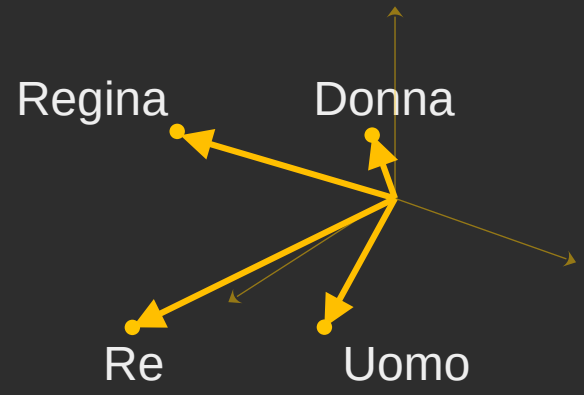

linuxday25@poul:~$ man Embedding

@ Embedding

- Un Token viene associato ad una rappresentazione in uno spazio multi-dimensionale
- **Angolo Tra Vettori = Somiglianza di Significato**
- Bag of Word e Contesto

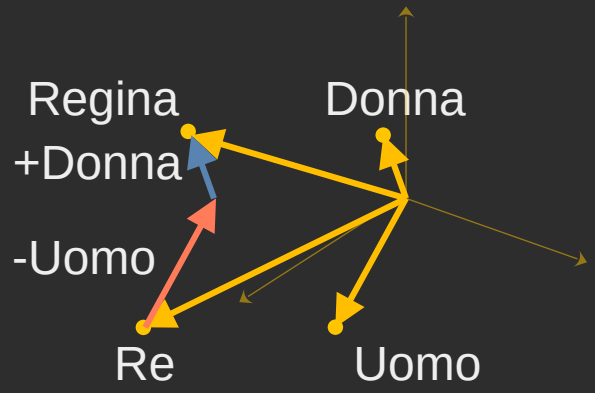

linuxday25@poul:~$ man Decoding

@Language Modeling Head

~ La LMH è il componente responsabile di effetturare l'operazione di un-embedding

~ E' una mappa dallo spazio vettoriale usato dal modello al vocabolario del tokenizer

@ Scelta del Token

~ Il risultato ritornato dalla LMH è un "punteggio" per ogni prossimo token

~ Con una SoftMax possiamo ottenere una distribuzione probabilistica

$$SoftMax(\vec{x}_i) = \frac{e^{x_i}}{\sum_j e^{x_j}}$$

linuxday25@poul:~$ python Embed&Decode.py

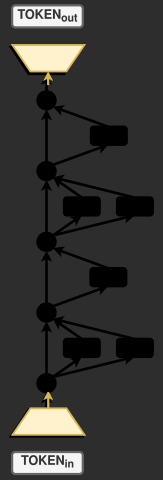

[Code Session]

Dentro un Transformer

linuxday25@poul:~$ man Transformer

@ Residuo

~ Tutti i componenti leggono il loro input e scrivono il loro output su un residuo comune

~ All'inizio il residuo rappresenta l'input, alla fine il token successivo

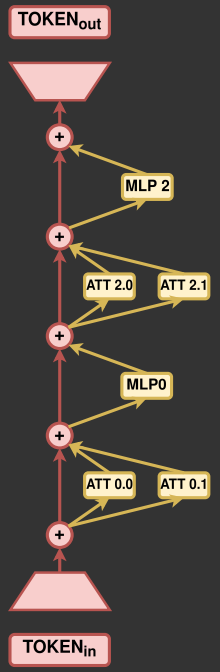

@ Componenti

~ In una struttura modulare in blocchi (layer)

~ Ogni modello presenta Normalizzazione, Attenzione e Multi-Layer Percepron

linuxday25@poul:~$ python Model.py

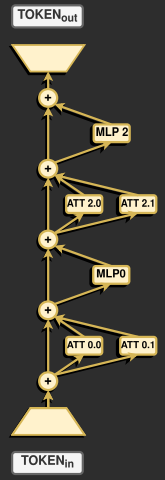

[Code Session]

linuxday25@poul:~$ man Layer Normalizzazione

@ Stabilizzazione

~ Uniforma l’intensità dell’informazione in input ad ogni componente

~ Velocizza la convergenza evitando problemi di ottimizzazione

~ Assegna un’importanza alle feature

@ Formula

~ La Layer Normalizzazione è una normalizzazione lungo le feature:

$$y = \frac{x - \mu}{\sqrt{\sigma^2 + \epsilon}} \cdot \gamma + \beta$$

linuxday25@poul:~$ man Neurone

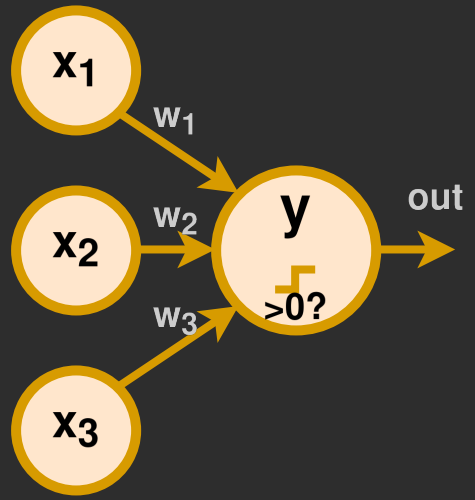

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = act\left(\begin{bmatrix} w_1^1, w_1^1, \ldots, w_n^1 \\ w_1^2, w_1^2, \ldots, w_n^2 \\ w_1^3, w_1^3, \ldots, w_n^3 \\ w_1^4, w_1^4, \ldots, w_n^4 \\ w_1^5, w_1^5, \ldots, w_n^5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \right)$$

linuxday25@poul:~$ man MLPs

@ Come?

~ Trasformazioni lineari

$$\vec{y} = W\vec{x} + b$$

~ Intervallate da funzioni di attivazione non-lineari

$$y = GELU(x)$$

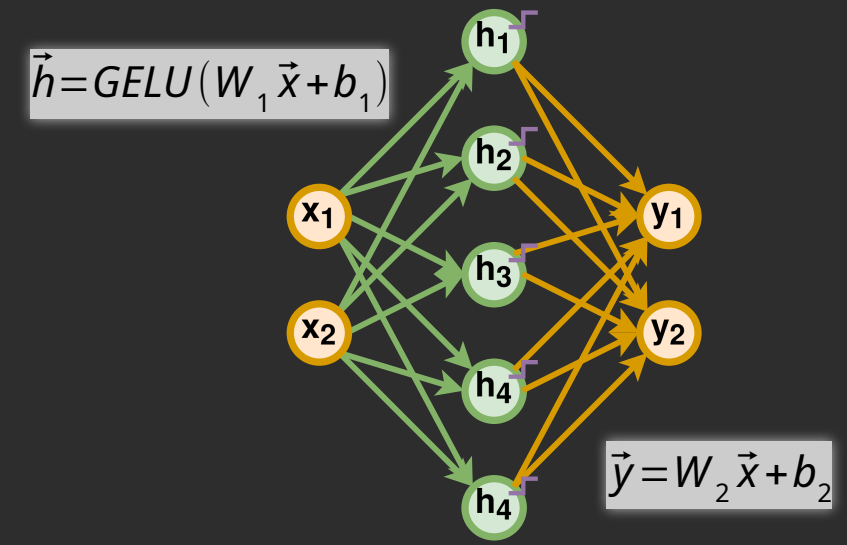

linuxday25@poul:~$ man MLPs

@ Teoria

~ Un MLP a singolo layer sufficientemente largo può approssimare qualsiasi funzione

~ Creare più layer riduce la quantità di neuroni richiesti

@ Negli LLM

~ Svolgono il ruolo di essere la "memoria" dell'LLM (*probabilmente)*

~ Compongono gran parte dei parametri del modello

~ Intervengono solo sul token corrente

linuxday25@poul:~$ python LN&MLPs.py

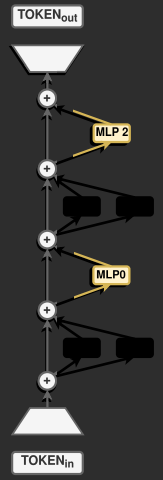

[Code Session]

linuxday25@poul:~$ man Attenzione

@ Pratica

~ É l’elemento che permette al modello di “ragionare”

~ Raccoglie informazioni dai residui associati a **TUTTI I TOKEN!**

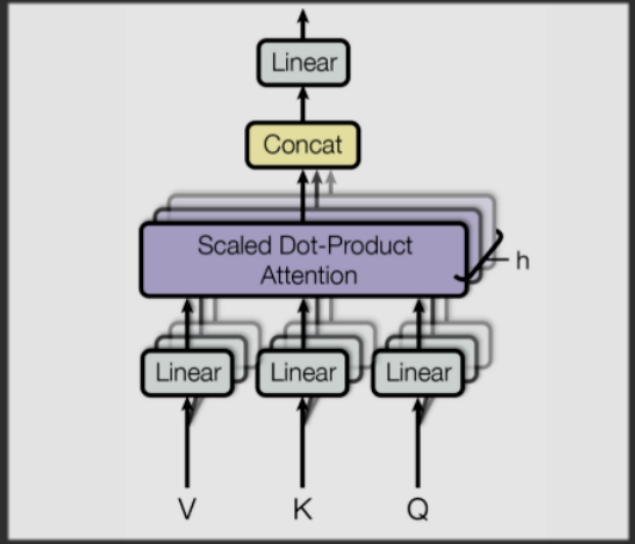

linuxday25@poul:~$ man Attenzione

@ Come?

~ Proietta i residui in tre spazi vettoriali:

$ **Query**

$ **Key**

$ **Value**

~ Copia i valori sulla base di corrispondenza tra key e query

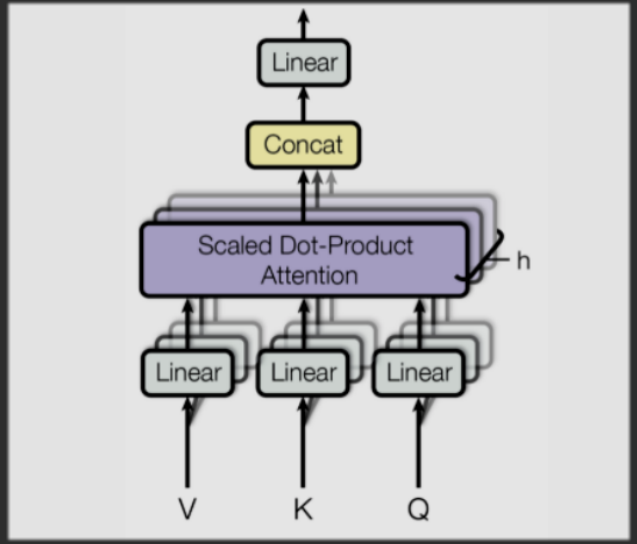

linuxday25@poul:~$ man Attenzione

@ Intuizione

~ Prompt: “Le mele sono verdi, una mela di colore ___”

~ **Query = “cosa cerco”** → pos.` colore`: “Il colore della mela”

~ **Key = “cosa sono”** → pos.` verdi`: “io sono colore delle mele”

~ **Value = “che informazione porto”** → pos.` verdi`: “verde”

Query e Key sono molto simili e quindi voglio copiare l’informazione associata a ` verdi` nel residuo corrente in modo da “raccogliere” l’informazione sul colore

linuxday25@poul:~$ man Attenzione

@ Come?

~ Proietta i residui in ogni posizione *i* in tre spazi vettoriali usando 3 layer lineari:

$$\mathbf{query}_i = W_q \cdot r_i + b, \qquad \mathbf{key}_i = W_k \cdot r_i + b_k, \qquad \mathbf{value}_i = W_v \cdot r_i + b_v$$

~ Copia i valori sulla base di corrispondenza tra key e query:

1. Calcola la matrice delle delle **cosine similarities** ($cosim_{ij}(q_i,v_j) = (q_i \cdot v_j)/(||q_i|| \cdot ||v_j||)$)
2. Per ogni query applica una softmax ottenendo la matrice degli **scores**
3. Copia nel residuo *di* q_i, i valori v_j per ogni $j \leq i$ pesandoli in base a scores[i,j]

linuxday25@poul:~$ man Attenzione

@ Come?

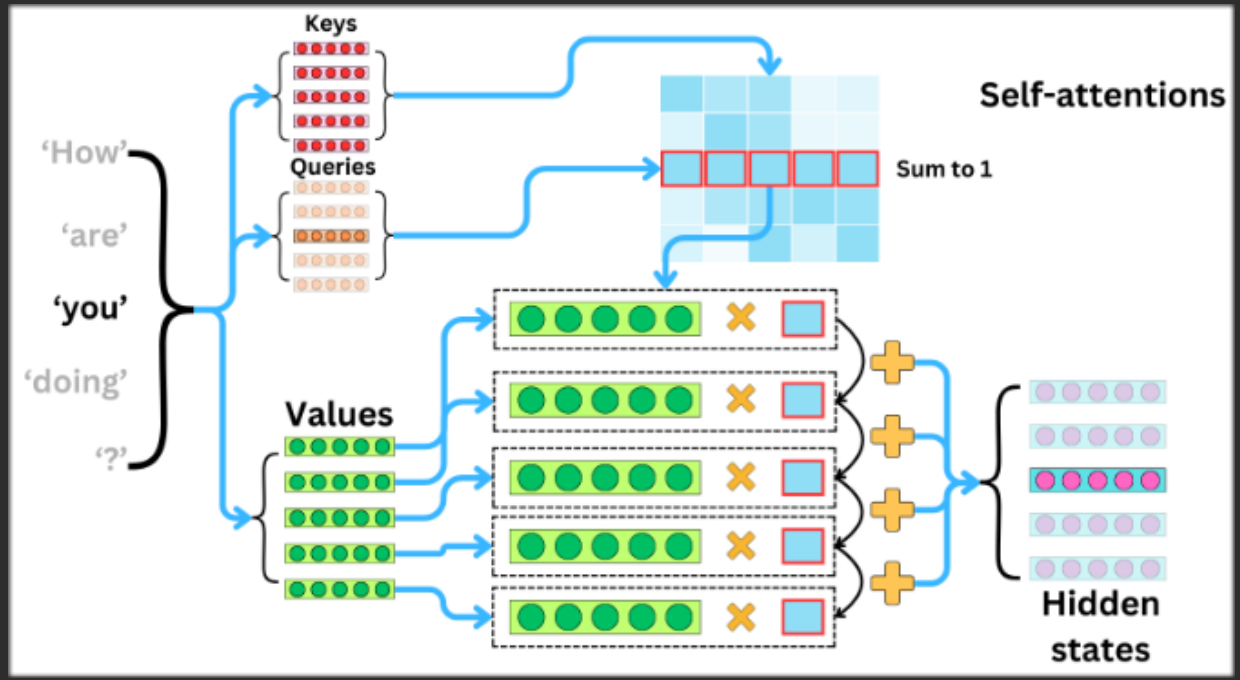

linuxday25@poul:~$ python Attention.py

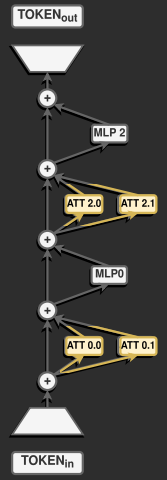

[Code Session]

linuxday25@poul:~$ man Training

@ Machine Learning

~ Ingredienti:

$ Esempi di input – output

$ Un modello e come addestrarlo

~ Risultato:

$ Il modello impara a produrre l'output atteso dato un input

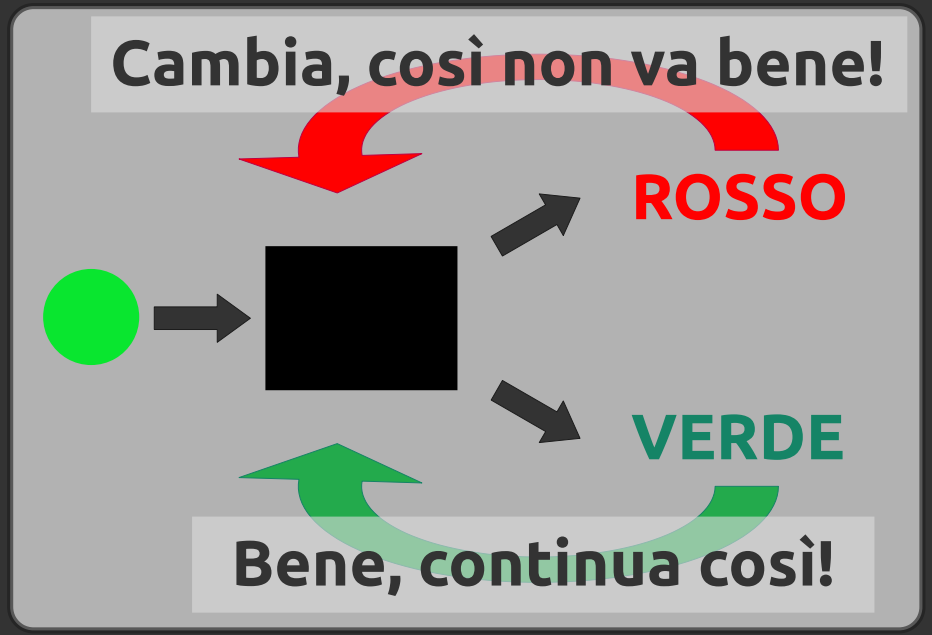

linuxday25@poul:~$ man Back Propagation

@ Idea

- Il modello al suo interno ha tante manopole
- Non sapendo cosa fa una manopola la giro un pochino a destra e sinista vedendo se il modello fa meglio o peggio (calcolo la derivata discreta!)

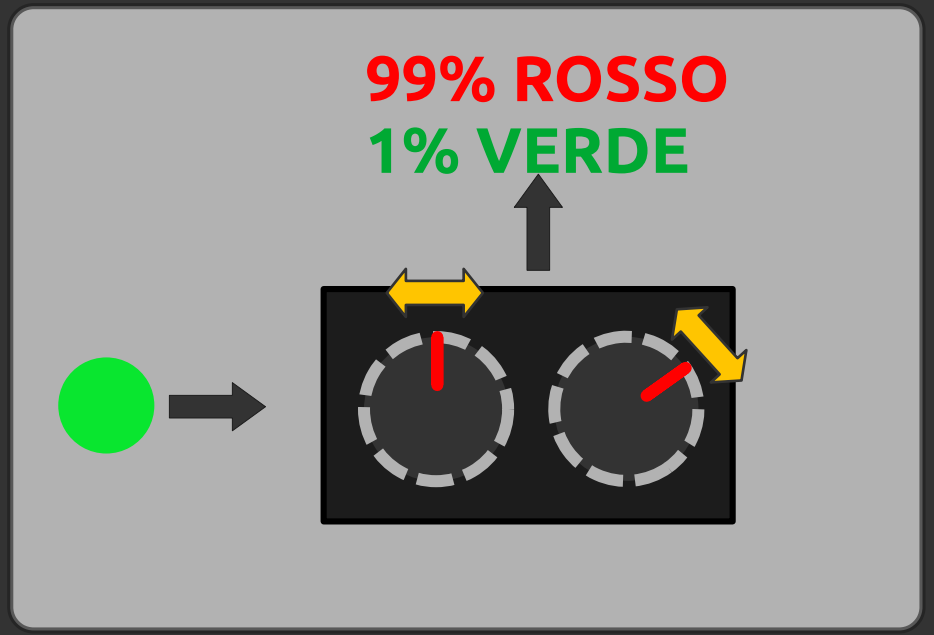

linuxday25@poul:~$ man Back Propagation

@ Idea

- Il modello al suo interno ha tante manopole
- Non sapendo cosa fa una manopola la giro un pochino a destra e sinista vedendo se il modello fa meglio o peggio (calcolo la derivata discreta!)

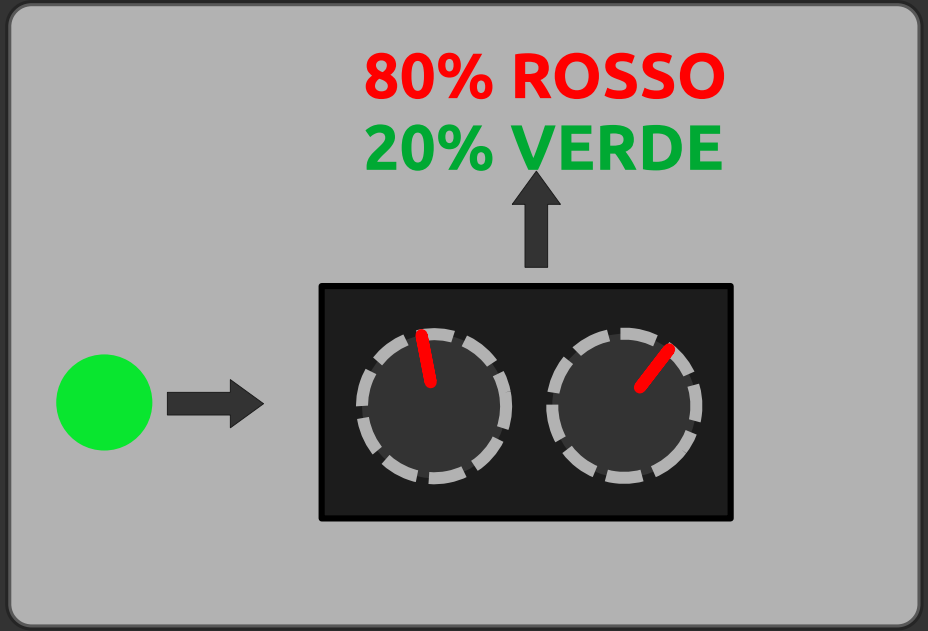

linuxday25@poul:~$ python Training.py

[Code Session]

[Grazie per l’ Attenzione]